图约束问答：路径修复与评价核查

研究问题：在不更换模型架构的前提下，修好知识与训练路径，能否让回答更有依据？

研究对象

知识图谱＝实体和关系组成的事实网；路径＝沿事实走出的解题路线。
沿用GCR（图约束推理）框架，重点改训练材料、图表示和评价，不另建agent答题系统。

已完成的工作

审计训练漏题、建图丢关系和测试资料缺口；实现多关系保留与训练选路改进。
完成两题库、两方案各3个训练版本的全量评测；另做补路实验和80题AI初审。

当前主要结果

C2相对A_multi：修正忠实命中在WebQSP上提高2.4个百分点，在CWQ上提高1.8个百分点。
答案命中率没有提高；上述分数仍不能代表完整推理正确率。

本次汇报要讨论什么

区分三个问题：资料是否齐全、模型是否选对路线、评价是否核对全部条件。
建议先完善评价并复用现有预测，再决定是否投入新的训练与补路实验。

汇报主线：发现问题 → 针对性修复 → 公平对照与逐题检查 → 结果及下一步。

[1][2][3] 项目结果截至2026-11-08；汇报整理于2026-11-09

原论文铺设生成轨道，我们修复轨道与教材

保留GCR的基本框架；原论文的“路径有图依据”，与“路径证明了全部问题条件”并不等价。

原论文：训练怎样做

从问题实体到已知答案实体搜索最短路径，构成“问题 → 路径＋答案”的训练示范。
优势是自动构造成本低；风险是最短路可能碰到答案，却没有体现问题真正问的关系。

原论文：答题怎样做

先把允许路径编成KG-Trie（路线前缀树），模型沿树生成候选路径；路径结束后答案恢复普通生成。
再由通用大模型综合多条证据。主设置为2跳、10条候选；论文也测试不同模型规模。

我们：改动在哪里

保留实体间已有的多种关系；C2用训练标准查询筛选、排序示范路径。
另外探索训练图池修复和答题时补路；修正自建评分规则，并核验统计与逐题证据。

比较范围必须对齐

当前主评测使用官方Qwen2-0.5B检查点继续微调，2跳、2条候选，重点评价前段候选。
没有同配置的第二阶段通用模型；不能直接对比论文最终答对率，也不能将单路径不足等同于联合推理失败。

2跳＝每条路线最多走两条边；2条候选＝最终保留两种解法。二者不是同一个限制。

[4] 原论文v2 §3 - 5；[5] 原论文与我们的方法对照；官方实现

发现的问题：漏训练题、丢关系、缺测试证据

这些问题各有独立证据，但不能合并成“数据集导致了全部错误”的结论。

训练资料缺口：20.1%	CWQ共27,639道训练题，官方构造跳过5,551题，其中5,550题的答案不在单题子图。合并训练图池后，在5,543道有效被丢题中，约77%可在3步内重新到达答案；到达不代表路线正确。
建图丢关系：7.3% / 30.1%	同一对实体可同时存在“导演、编剧、出演”等关系，简单图的后写关系覆盖前写关系。WebQSP三元组在有向/无向建图下分别丢失约7.3%/30.1%；保留多关系修复的是信息损失，不是新增事实。
测试资料缺口：19.3% / 4.4%	CWQ的683/3,531题、WebQSP约4.4%的题，参考答案实体不在原子图；CWQ嵌套题型缺口达38.2%。 这限制了仅靠当前图给证据，不意味着模型无法凭记忆或外部资料回答，更不等于标答一定错。

关键假设：先保证资料不丢，再提高示范路线质量；仅仅“搜到答案”不足以形成可靠教材。

[1] FINDINGS E/H/O/T/Z；各数字分母与审计设置不同，不是同一漏斗

解决方案与实施：保关系、选好路、分开做扩充

核心原则：不编造事实、不让agent编题；利用现有训练知识和标准查询构造更合适的示范。

① 多关系表示：先避免信息丢失	将“实体对 → 单一关系”改为“实体对 → 关系集合”，训练与推理使用相容表示。 例如同一人和电影之间的导演、编剧关系都保留。300题样本路径数中位数由2,039增至7,860，但2跳答案可达率未升。
② C2：优先教与问题有关的路线	提取训练SPARQL（标准查询）的关系 → 约束搜路 → 按同一查询、少反向步、少类型关系、长度排序。 每题默认用1条示范；约束搜路无结果时回退。构造阶段WebQSP/CWQ分别有47/651题回退，并非所有路径都严格合规。
③ D2：把可修复的训练题加回来	合并训练子图并去重 → 以已知训练答案为目标搜路 → 用查询关系和捷径规则过滤 → 打包原问题、路径、原答案。 D2＝C2＋图池找回的≤2跳题，构造包新增832题，训练前仍过滤原题重叠；不是给C2统一扩到3/4跳。

全量主结果比较C2与A_multi，两者都保留多关系；D2数据扩充与答题补路是不同探索分支。

[5][6] multi_relation_graph.py、build_v2.py、v2_stats.json；[1] FINDINGS O/R

如何验证：公平对照、规则评分、按题家族统计

把“模型学得更好”与换图、多训练、抽样偶然以及评分漏洞尽量分开。

同条件主对照

A_multi＝对照训练材料；C2＝改进选路材料。二者均从官方0.5B检查点继续LoRA微调（只训练少量附加参数）。采用相同推理图、候选数和训练轮数；不是把额外训练收益算成选路收益。

全量＋重复训练

WebQSP 1,628题、CWQ 3,531题；两方案各用42/43/44三个随机设置训练，共12组全量预测。CWQ来自344个原题家族，先平均各题三次结果，再按家族一起抽样和检验，避免把关联题当成独立证据。

评分由程序完成，不是agent裁决

Hit＝候选答案是否命中标答；修正忠实命中＝同一候选命中，且路径审计有效、关系符合某个标准查询、无类型捷径。已合并互逆关系名称；全量评分采用官方子串答案匹配。测试查询用于离线评分，不作为普通解码输入。

规则仍有边界，另做AI诊断

关系集合符合查询，不保证日期、人数、第二实体等条件都被证明；评分没有执行完整查询。因此另做80题AI初审。两者均属离线评价，尚无agent发现错误后要求模型重答的在线闭环。

我们修正的是自己新增的评分器；三个训练版本也不足以覆盖任意训练随机性。

[2][3][7] run_full_seeds.py、score_faithfulness.py、审阅记录；[1] FINDINGS S/W/AA

全量结果：关系一致性改善，答案命中未提高

单位均为“百分点”；区间与检验按原题家族计算，不是只看一次训练或前500题。

题库与指标	变化	95%置信区间	p值
WebQSP · 修正忠实命中	+2.4	[+0.8, +4.1]	0.0024
CWQ · 修正忠实命中	+1.8	[+0.2, +3.5]	0.032
WebQSP · 答案命中	-0.1	[-1.6, +1.3]	0.89
CWQ · 答案命中	-1.0	[-2.4, +0.5]	0.19

支持的结论

当前自动指标上的增益通过本次统计检验；选路质量改善有证据支持，但改善幅度有限。

不能推出的结论

不能宣称整体答对率提高、完整推理总体提升或没有代价；CWQ答案命中点估计反而下降。

统计显著 ≠ 效果很大 ≠ 指标完全有效；“未检出下降”也不等于“证明无损”。

[2] FULL_SEEDS_REPORT最终3v3行；[1] FINDINGS AA；主实验12组全量预测

扩展实验：答题时补路已经跑过，但收益未确认

用问题预测关系，从训练图池搜最长3步、最多约100条路线加入轨道；选路不读取测试标答或标准查询。

策略	答案命中率	修正忠实命中	新增答对 / 答错
不补路（local）	46.2%	37.8%	—
每题补（always）	47.2%	38.6%	+5 / 0
检测缺口再补（gated）	46.6%	38.0%	+2 / 0

真正用上的新路很少

每题补路的1,000条输出候选中，仅14条用了新增边。111道缺答案题中107道加了路线，只有4道被救回；加路线不等于补到正确证据。

尚未定位唯一瓶颈

每题补的Hit差异p=0.13；按需补p=0.50。模型只保留2条候选，且该设置未训练3跳示范；搜索覆盖、排序与训练分布的影响尚未分开。

下一步应分别量“正确路有没有搜到”和“搜到后有没有选中”，不是继续盲目扩大候选。

[1] FINDINGS U/V/Y；[8] cwq_completion_500/comparison.json；y_completion_eval.py

80题AI初审：真实改善、漏条件与数据异常并存

两题库各40题，按自动改善、退步、双方通过、双方未通过各抽10题；共审阅320条候选。

真实改善与退步都存在

自动判改善的10题中，WebQSP有6题、CWQ有2题被AI判为完整单路径改善。
例R065：问球员位置，从“执教／主教练”改为“球员／右护锋”；反例R044：问母亲却改走到女儿。

自动规则会放过漏条件

R012问“就读过、且有3,565名研究生的大学”，路径只证明就读，没有证明人数。
CWQ改善组另有6题双方未通过、1题双方通过、1题不确定。关系名称对上，不代表题目全部条件得到支持。

数据异常只能归因到已核查来源

R024题面问摄影师，标答却是两部电影；已在所用RoG-CWQ文件确认，另有2条明显异常记录。
尚未追溯最初CWQ发布版，也不能由3条异常估计总体错误率，或证明小幅提升主要由数据导致。

AI初审非独立人工双盲；单路径口径不等于多路径联合。不能用6/10、2/10乘以全量增益。

[3] AI审阅报告；[9] summary.json、judgments.jsonl、dataset_anomalies.json

阶段价值与瓶颈：把问题拆开，而非只追分数

当前可支持的主张：训练选路提高了关系一致性代理指标，并有真实改善案例；完整推理提升仍待核验。

亮点一：问题有可追踪证据

从训练漏题到图池修复、从关系覆盖到多关系表示，形成可运行脚本与明确对照。
不是让agent造事实，而是核查已有数据如何进入模型；每类问题都可定位到数据或实现步骤。

亮点二：主动检验研究结论

冻结修正评分，补齐12组全量预测，并考虑原题家族相关性；保留80题逐候选理由与不确定项。
不沿用更好看的旧分数，也不将AI诊断伪装成人工验证；实验可以继续复核和重算。

瓶颈一：可达、可选、完整不同

图池可能补到路线，模型可能不选；选中相关关系，也可能漏掉第二实体或日期条件。
需要分别量化资料覆盖、候选选择和完整支持，不能用一个自动分数替代全部环节。

瓶颈二：收益有限且有适用边界

主指标提升小、答案命中未升；多关系增加路径规模，训练选路依赖标准查询这一额外监督。
当前未接同配置的第二阶段；没有证明换大模型就有效，也未完成新颖性和跨设置验证。

目前值得汇报的是可复核的诊断与有限方法增益；还不是“完整推理能力显著提升”的最终结论。

[1][2][3][5] 本地实验、审阅与方法对照；研究贡献的新颖性仍需进一步文献定位

下一步：先测清完整证据，再决定继续优化哪里

把下一阶段变成有明确产物和判断标准的验证，而不是继续堆实验。

第一步：冻结评价目标与规则	分开报告答案命中、关系一致、全部条件支持；区分单路径与多路径联合。 先核对方向、答案终点、第二实体、日期和数值；无法可靠核验的样本单列。产物：规则说明与独立核验样本。
第二步：重算与分层数据审计	复用现有12组预测，报告可核验覆盖率、不确定项、原版成绩及答对率代价。 分别看证据齐全／缺失、单条件／多条件；核查题面、标准查询与标答冲突，保留原始版本，不删难题抬分。
第三步：按证据选择后续路线	若完整证据仍有稳定收益：用同条件对照验证训练选路，并考虑第二阶段联合推理。 若提升主要来自评分偏差：聚焦评价与数据诊断；若正确补路已搜到却未选中：再做候选数、排序、3跳训练的单因素实验。

请老师重点讨论：先验证“完整推理”的评价有效性，再决定新增训练和方法扩展，是否合适？

[3] AI审阅报告“下一步”；STATUS_AND_NEXT当前计划；本页为建议，非已完成结果