知识图谱问答 · 阶段汇报

从修补训练路径，到重新检验推理质量

前期发现、全量实验与下一步验证

已经做到	找到数据与流程缺口，完成全量对照实验
现在卡在	自动分数提升，尚不等于完整推理提升

2026.11.09 / 14页正文 + 2页附录

我们想让模型不只答对，还要说清为什么

把知识图谱想成“事实地图”，把推理路径想成“解题路线”。

01	知识图谱	一个点是人、地点或作品；一条边是一条带方向的事实。
02	GCR：图约束推理	模型只能沿预先允许的路线生成路径，减少编造不存在的边。
03	我们的切入点	模型照着“题目＋标准路径”学习；如果教材编错或漏题，能否修好？

示意：人物 → 出生城市 → 所属国家。路线存在，不代表它回答了题目。

我们已经走完一条“发现—修复—验证”链条

不是只训练了一个模型，而是把数据、实现、指标和结论逐层核查。

01	查教材	统计被跳过的训练题；拼接训练图池，寻找缺失路径。
02	修流程	保留多种关系、修正选路问题；构造不同训练材料做对照。
03	查评分	修正关系名与类型捷径；统计改为按原题家族重采样。
04	做验证	完成两套题库全量、两组各3次训练版本评测；AI审阅80题。

当前阶段：自动指标实验已完成，完整推理效果仍待独立验证。

前期发现一：教材漏题，补路也不能只图近

CWQ是较复杂的问答题库。官方路径构造会跳过找不到答案路线的训练题。

20.1%

CWQ训练题被跳过：5,551 / 27,639；其中5,550题答案不在子图。

约77%

在合并后的训练图池中，3步内可为被丢题重新找到路线。

仅2.4%

早期审计中，修复最短路的关系与标准查询一致的题占比很低。

加上标准查询关系约束与捷径过滤后，仍可修复约62 - 75%；不等于完整证明。

前期发现二：同一对实体之间，关系被覆盖了

例如某人既是导演又是编剧，简单建图可能只保留最后写入的那种关系。

01	发现的问题	WebQSP测试子图中，有向建图约丢7%的边；忽略方向建图约丢30%。
02	已经修复	改为保留多种关系，并支持反向遍历；修正训练路径选择问题。
03	公平比较	对照版A_multi与修复版C2使用同类推理图、相同模型规模和训练轮数。

> 这样更接近回答“改教材有没有用”，而不是把换图或多训练的收益混进去。

前期发现三：考试资料里，也可能没有答案

下面是参考答案实体不在题目自带子图中的比例，不是整体答错率。

CWQ **19.3%**



WebQSP **4.4%**



同一比例尺：0%—100%（整条代表全部测试题）

CWQ嵌套题型缺口达38.2%，但成因还需逐题核查。

> 限制的是“只靠这张子图给证据”；不限制模型凭记忆或外部检索作答。

我们试过考试时补资料，但模型很少采用

CWQ前500题，固定C2训练版本；每题补入最多约100条、最长3步的候选路径。

答案命中率

46.2% → 47.2%

14 / 1,000

只有14条输出候选使用了补进来的边。

尚未确认收益

按原题家族计算p=0.13；只在检测器报警时补，命中率为46.6%。

> 补进来 ≠ 选出来。候选排序、训练分布、生成宽度的影响尚未拆开验证。

分数一度很好看，后来发现评分器也有问题

我们自己设计的“忠实度”评分，经历了两次认识修正。

01	已修：同义关系被误罚	“导演→电影”和“电影→导演”可能表达同一事实，不能只比较名字。
02	已修：类型捷径被放过	从“国家”类别列举国家碰到答案，不等于按问题推理。
03	仍缺：完整条件核验	路径关系都在标准清单中，仍可能漏掉人数、日期或第二个人物。

> 当前“修正忠实命中”＝答案命中＋关系一致等检查；不是完整推理正确率。

为避免偶然，我们补齐了全量与多次训练对照

两种方案 × 每种3个训练版本 × 两套题库，共12组全量预测。

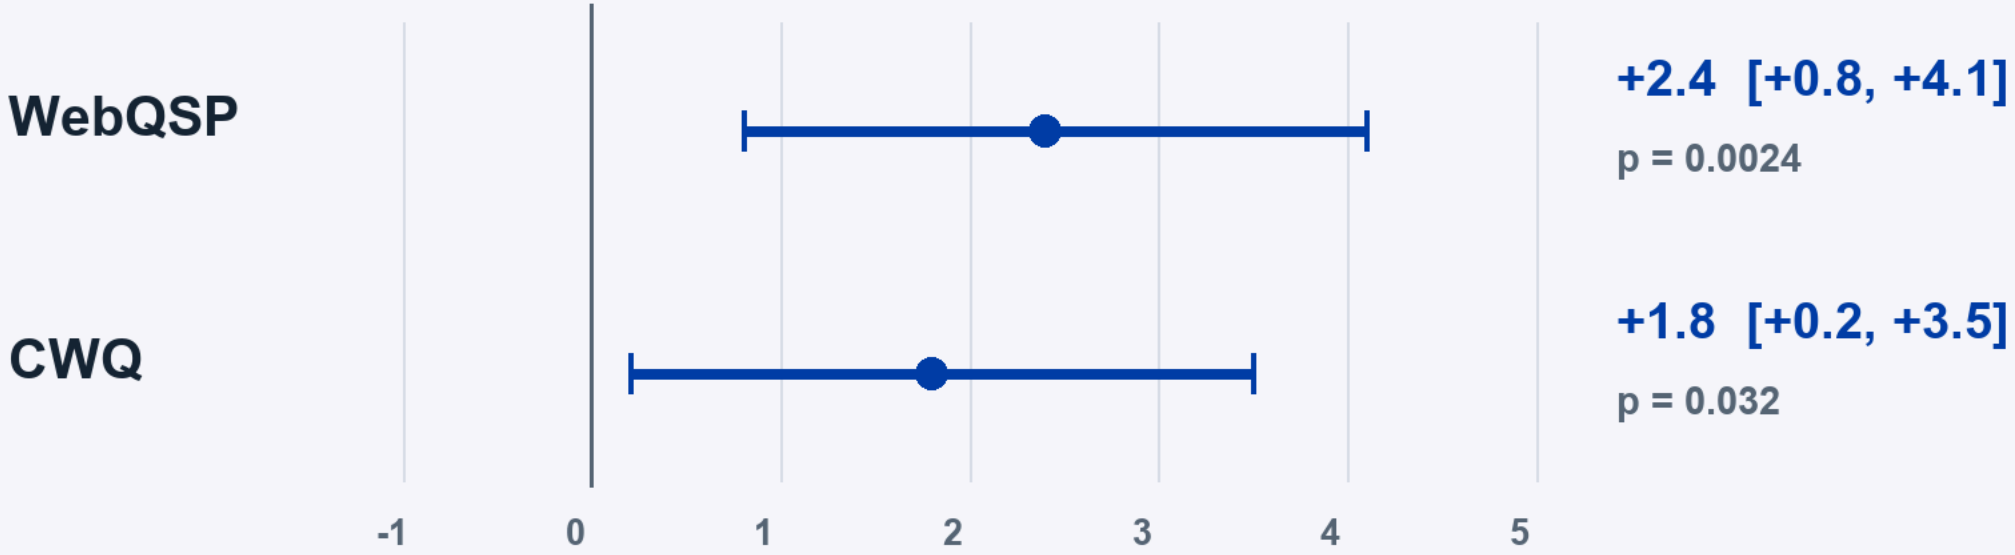
01	同等条件对照	A_multi＝对照版；C2＝修复版。使用0.5B模型和LoRA微调。
02	训练随机性	seed 42 / 43 / 44决定训练中的随机选择；不是三套不同测试题。
03	题目不是完全独立	CWQ的3,531题来自344个原题家族；同一家族一起抽样统计。

> 训练seed是“重复实验的随机设置”；种子题是“改写题的原题”，两者不同。

全量结果：自动指标小幅提高，答对率没有提高

两组各3个训练版本合并；下列变化单位均为“百分点”。

答案命中率：WebQSP -0.1点 ／ CWQ -1.0点



修正忠实命中变化（百分点）；横线表示95%置信区间

这些结果支持当前自动指标上的差异，不能替指标证明“完整推理变强”。

80题AI初审：有真实改善，也有指标漏检

两套题库各40题，每题两方案、每方案两候选；共320条逐项判断。



AI初审，非独立人工验证；有意分层抽样，不能用6/10或2/10乘全量提升。

ai_review_2026-11-08/summary.json、judgments.jsonl、frozen.json

三个例子，把方法、评分和数据问题分开

不是“方法全没用”，也不是“全怪数据集”。

证据 01

方法真的改好 · R065

问球员位置：从“执教经历／主教练”改为“球员位置／右护锋”。

证据 02

评分放过漏条件 · R012

问读过且有3565名研究生的大学；路径只证明读过，没查人数。

证据 03

所用数据有异常 · R024

题面问摄影师，参考答案却是两部电影；本地RoG-CWQ文件已核实。

也有真实退步：R044问母亲，修复后却走到女儿。不能只挑成功案例。

目前最有价值的是诊断证据，不是一个大幅涨分故事

方法可以保留，但论文主张必须比自动分数更谨慎。

01	亮点：问题可定位	训练漏题、建图丢边、评分缺陷、题目成簇，都有记录与可复核数字。
02	瓶颈：三个层次	资料够不够？模型能否选出正确路径？评分是否核对全部条件？
03	尚未证实	完整推理总体提升；数据问题是主要原因；换大模型即可解决。

> 当前安全表述：关系一致性代理指标提高，并存在真实路径改善案例。

下一步：先把“完整推理”测清，再决定继续训练

优先复用已有全量预测，暂不新增大规模GPU训练。

01	定义并冻结新规则	答案命中、关系一致、全部条件满足分开报；单路径与多路径联合分开评。
02	小范围验证评分	先检查方向、终点、第二实体、日期/数值；无法核验单列，不强行判错。
03	重算与独立核验	重算已有12组预测；再取独立样本复核，报告覆盖率、不确定项与答对率代价。
04	用结果决定主线	若完整证据仍改善，继续方法验证；若不成立，重点研究评价与数据缺口。

> 这次汇报希望确认：优先投入评价有效性，而不是继续追求更高自动分数。

附录：汇报里的名词，换成大白话

不需要记缩写，只需要区分“资料、作答、评分、统计”。

01	子图 / 图池 / SPARQL	单题小资料包 / 合并训练资料库 / 出题人的查询与条件清单。
02	Hit / 修正忠实命中	答案是否碰到标答 / 答案命中且通过关系一致等检查；后者仍非完整证明。
03	p值 / 95%置信区间	无差异假设下这么极端结果有多罕见 / 重复抽样程序给出的差异不确定范围。
04	训练seed / 原题家族	重复训练的随机设置 / 多道改写题共同的原题；两种随机性不能混淆。

> p=0.032不是“方法有3.2%概率无效”；区间也不保证覆盖未建模的所有误差。

附录：所有结论都有对应记录

以原始结果和逐题记录为准；早期阶段报告包含历史结论。

01	前期发现与方法变更	gcr-lab/experiments/FINDINGS.md：E/H/M/N/O/R/S/W/Y/Z/AA。
02	全量主结果	cuda_results/FULL_SEEDS_REPORT.md：最终3v3合并行；12组预测已完成。
03	审阅过程与异常	eval/ai_review_2026-11-08/：逐题原文、320条标签、冻结指纹、3条异常源数据。
04	通俗结论与下一步	AI审阅报告_2026-11-08.md；gcr-lab/STATUS_AND_NEXT.md。

> 本汇报未新增训练、未修改标答；AI初审不是独立人工验证。

本地仓库；完整相对路径与文件指纹见随附证据索引.json